

**DETEKSI PENYAKIT PARU MENGGUNAKAN
METODE *SMART DATA PAIRING* DAN *DECISION
FUSION* UNTUK INTEGRASI CITRA X-RAY DAN
SUARA PARU**

TESIS

Sebagai Salah Satu Syarat Untuk Memperoleh Gelar


MAGISTER TEKNIK

Pada Program Studi Magister Teknik Elektro

Oleh

Yudi Candra

NIM: 2404205010016



**PROGRAM STUDI MAGISTER TEKNIK ELEKTRO
FAKULTAS TEKNIK UNIVERSITAS SYIAH KUALA
DARUSSALAM, BANDA ACEH
NOVEMBER 2025**

LEMBAR PENGESAHAN

Tesis

DETEKSI PENYAKIT PARU MENGGUNAKAN METODE *SMART DATA PAIRING* DAN *DECISION FUSION* UNTUK INTEGRASI CITRA X-RAY DAN SUARA PARU

Disusun oleh :

Yudi Candra


NIM: 2404205010016

Program Studi Magister Teknik Elektro
Departemen Teknik Elektro dan Komputer
Fakultas Teknik Universitas Syiah Kuala

Banda Aceh, 12 Januari 2026

Disetujui oleh,


Pembimbing I



Prof. Dr. Ir. Roslidar, S.T., M.Sc., IPM., ASEAN Eng.

NIP. 1978071920021220002

Pembimbing II



Dr. dr. Mulkan Azhary, M.Sc., Sp.P.

NIP. 198108022005011001

Disahkan Oleh,

Koordinator Program Studi Magister Teknik Elektro



Prof. Dr. Ir. Roslidar, S.T., M.Sc., IPM., ASEAN Eng.

NIP. 1978071920021220002

ABSTRAK

Tuberkulosis (TB) terus menjadi ancaman kesehatan global yang signifikan, sehingga memerlukan metode diagnosis yang cepat, akurat, dan mudah diinterpretasikan. Penelitian ini mengajukan sebuah kerangka kerja *deep learning* multimodal yang berlandaskan praktik klinis dengan menggabungkan data citra rontgen dada (CXR) dan rekaman suara paru untuk mendeteksi TB. Untuk mengatasi ketiadaan dataset tersinkronisasi, dikembangkan mekanisme *Lesion-Guided Smart Data Pairing* yang memanfaatkan pelokalan lesi berbasis YOLOv8 guna mencocokkan data visual dan akustik secara relevan terhadap posisi anatominya. Dataset hasil pemetaan terdiri dari 450 citra CXR dan 2.700 rekaman suara paru, yang diproses menggunakan arsitektur dua cabang: *encoder* ResNet50 untuk ekstraksi fitur visual dan CRNN untuk representasi akustik. Keluaran probabilistik keduanya digabungkan melalui strategi *Weighted Average Fusion*, dengan bobot optimal $W_{cxr} = 0.51$ dan $W_{audio} = 0.49$ yang ditentukan berdasarkan nilai AUC hasil validasi unimodal. Hasil eksperimen menunjukkan bahwa kerangka yang diusulkan memberikan kinerja lebih baik ($Accuracy = 0.92$, $AUC = 0.983$) dibandingkan model unimodal CXR ($Accuracy = 0.90$, $AUC = 0.95$) dan ($Accuracy = 0.73$, $AUC = 0.81$). Studi ini menawarkan pendekatan multimodal yang efisien terhadap data dan selaras dengan konteks fisiologis untuk skrining TB, sekaligus menjadi landasan bagi pengembangan sistem diagnosis berbantuan AI yang dapat diterapkan secara klinis.

Kata Kunci: Tuberkulosis, Multimodal *Deep Learning*, *Smart Data Pairing*, *Late Fusion*, YOLOv8

ABSTRACT

Tuberculosis (TB) remains a significant global health threat, necessitating diagnostic methods that are fast, accurate, and clinically interpretable. This study proposes a clinically grounded multimodal deep learning framework that integrates chest X-ray (CXR) images and lung sound recordings for TB detection. To address the absence of synchronized multimodal datasets, a Lesion-Guided Smart Data Pairing mechanism is developed, leveraging YOLOv8-based lesion localization to anatomically align visual and acoustic data. The resulting paired dataset comprises 450 CXR images and 2,700 lung sound recordings, which are processed using a dual-branch architecture: a ResNet50 encoder for visual feature extraction and a CRNN for acoustic representation learning. The probabilistic outputs from both branches are fused using a Weighted Average Fusion strategy, with optimal weights of $W_{cxr} = 0.51$ and $W_{audio} = 0.49$, derived from unimodal validation AUC values. Experimental results demonstrate that the proposed framework outperforms unimodal CXR (Accuracy = 0.90, AUC = 0.95) and audio-only models (Accuracy = 0.73, AUC = 0.81), achieving an overall performance of Accuracy = 0.92 and AUC = 0.983. This study presents a data-efficient and physiologically aligned multimodal approach for TB screening, providing a solid foundation for the development of clinically deployable AI-assisted diagnostic systems.

Keyword: Tuberculosis, Multimodal Deep Learning, Smart Data Pairing, Late Fusion, YOLOv8

PERNYATAAN KEASLIAN TESIS

Dengan ini saya menyatakan bahwa :

- 1) Tesis ini merupakan hasil kerja saya sendiri dengan masukan dari pembimbing
- 2) Seluruh material dan teks pada tesis yang bukan berasal dari hasil kerja saya, telah dikutip atau disebutkan sumbernya.
- 3) Apabila ternyata dalam tesis ini terdapat bagian-bagian yang memenuhi unsur penjiplakan, maka saya bersedia untuk dibatalkan sebahagian atau seluruh hak dari gelar magister saya.

Darussalam, 12 Januari 2026




Yudi Candra

HALAMAN PERSEMBAHAN

Segala puji dan syukur penulis panjatkan ke hadirat Allah SWT atas segala rahmat dan hidayah-Nya, sehingga penulis dapat menyelesaikan tesis yang berjudul “Deteksi Penyakit Paru Menggunakan Metode Smart Data Pairing dan Decision Fusion untuk Integrasi Citra X-Ray dan Suara Paru”. Penyusunan tesis ini dapat terlaksana dengan baik berkat bantuan, bimbingan, serta dukungan dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis menyampaikan rasa terima kasih yang sebesar-besarnya kepada:

1. Allah SWT yang telah memberikan rahmat dan hidayah-Nya sehingga laporan ini dapat diselesaikan dengan baik.
2. Ayahanda Hamdinur, S.E. dan Ibunda Juni Haryanti, S.E., serta saudara Zulfahmi yang senantiasa memberikan doa, semangat, dukungan, kasih sayang, serta bantuan moral dan material sehingga penulis dapat menyelesaikan tesis ini.
3. Seluruh komite persetujuan tesis penulis yaitu;
 - a) Prof. Dr. Ir. Roslidar, S.T., M.Sc., IPM., ASEAN Eng.,
 - b) Dr. dr. Mulkan Azhary, M.Sc., Sp.P
 - c) Prof. Dr.Ir. Fitri Arnia, S.T., M.Eng.Sc., IPU.
 - d) Dr. Ir. Kahlil, S.T., M.Eng.
4. Seluruh Bapak/Ibu dosen serta staf Magister Teknik Elektro Universitas Syiah Kuala.
5. Seluruh Bapak/Ibu Aparatur Sipil Negara (ASN) di Dinas Perhubungan Aceh
6. Umairah Maghfirah, Muda Wali Samudra Pasai, Arief Rahby, Iqbal Malikussalam, Haris Fakhrian, Cut Salsabilla Azra, Khalisa Zahra, M Zaki selaku sahabat seperjuangan yang telah memberikan banyak dukungan, tenaga dan waktu untuk membantu penulis dalam perbaikan buku ini.
7. Teman-teman seperjuangan Magister Teknik Elektro Universitas Syiah Kuala

Banda Aceh, 12 Januari 2026


Yudi Candra

DAFTAR ISI

LEMBAR PENGESAHAN	i
ABSTRAK	ii
<i>ABSTRACT</i>	iii
PERNYATAAN KEASLIAN TESIS	iv
HALAMAN PERSEMBAHAN	v
DAFTAR ISI	vi
DAFTAR GAMBAR	viii
DAFTAR TABEL	ix
DAFTAR SINGKATAN	x
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	5
1.4 Relevansi Penelitian	5
BAB 2 TINJAUAN PUSTAKA	8
2.1 Anatomi Paru	8
2.2 Tuberkulosis	12
2.3 Modalitas Penyakit Tuberkulosis	14
2.4 <i>Preprocessing</i> CXR	17
2.4.1 <i>Gaussian Blur</i>	17
2.4.2 <i>Histogram Equalization</i>	17
2.5 <i>Preprocessing</i> Suara Paru	18
2.5.1 <i>Wavelet Denoising</i>	18
2.5.2 <i>Mel-Frequency Cepstral Coefficients</i> (MFCC)	19
2.6 <i>Object Detection & Segmentation</i>	19
2.7 <i>Multimodal Encoding</i>	21
2.7.1 <i>Image Encoder</i>	21
2.7.2 <i>Audio Encoder</i>	22
2.7.3 <i>Activation Function</i>	23
2.8 Data Fusion	24
2.8.1 <i>Late Fusion</i>	25
2.9 Metode Evaluasi	27

2.10 Penelitian Terkait.....	27
BAB 3 METODE PENELITIAN.....	31
3. 1 Alat dan Bahan Penelitian	31
3. 2 Tahapan Penelitian	31
3.2.1 Identifikasi Kebutuhan	32
3.2.2 Pengumpulan Data	33
3.2.3 Integrasi Multimodal.....	34
3.2.3.1 Input Data.....	35
3.2.3.2 <i>Data Preprocessing</i>	35
3.2.3.3 <i>Lesion-Guided Smart Data Pairing</i>	37
3.2.3.4 <i>Decision-Level Fusion</i>	44
3.2.4 Pengujian.....	46
3.2.5 Analisis.....	46
3.2.6 Kesimpulan dan Penulisan Laporan.....	47
BAB 4 HASIL DAN PEMBAHASAN.....	48
4. 1 Gambaran Umum	48
4. 2 Lingkungan Eksperimen	48
4.2.1 Konfigurasi Eksperimen untuk Deteksi dan Segmentasi Lesi	48
4.2.2 Konfigurasi Eksperimen untuk Decision-Level Fusion.....	49
4. 3 Hasil Model Deteksi Lesi dan Segmentasi.....	50
4. 4 Hasil Lesion-Guided Smart Data Pairing.....	55
4. 5 Hasil Pelatihan Unimodal.....	59
4. 6 Hasil Pelatihan Multimodal.....	61
4. 7 Visualisasi Grad-CAM dan Saliency.....	66
4. 8 Analisis Hasil & Diskusi	67
4. 9 Future Work.....	70
BAB 5 PENUTUP	71
5.1 Kesimpulan	71
5.2 Saran..	71
DAFTAR PUSTAKA	73

DAFTAR GAMBAR

Gambar 2.1 Anatomi Segmental Paru-paru Manusia [24]	8
Gambar 2.2 Citra Toraks dengan anotasi anatomi [26].....	10
Gambar 2.3 Kavitas Pada Area Atas Paru Penderita TB [28]	11
Gambar 2.4 Penebalan Pleura pada Penderita TB [29].....	11
Gambar 2.5 Distribusi Nilai Piksel Pada Dataset Shenzen (a) Normal (b) Tuberkulosis [33]	15
Gambar 2.6 Distribusi Nilai Piksel Pada Dataset Montgomery (a) Normal (b) Tuberkulosis [33]	16
Gambar 2.7 Ilustrasi Proses Clipping Histogram pada CLAHE [30]	18
Gambar 2.8 Nilai <i>Intersection over Union</i> (IoU) pada YOLO [45].....	20
Gambar 2.9 Perbandingan Arsitektur Jaringan ResNet [47].....	22
Gambar 2.10 Strategi <i>Fusion</i> dalam <i>Deep Learning</i> [8].....	24
Gambar 2.11 <i>Late Fusion</i> [36]	26
Gambar 3.1 Tahapan Penelitian	31
Gambar 3.2 Kerangka Kerja Integrasi Multimodal yang Diusulkan	34
Gambar 3.3 <i>Gaussian Blur</i> pada CXR.....	36
Gambar 3.4 Penerapan CLAHE pada CXR	36
Gambar 3.5 Visualisasi MFCC pada Data Audio Paru	37
Gambar 3.6 <i>Pipeline Lesion-Guided Smart Data Pairing</i>	38
Gambar 3.7 Arsitektur Fusi Multimodal dengan Pendekatan <i>Weighted Average</i>	44
Gambar 4.1 Kurva <i>Precision-Recall</i> Model Yolov8m-seg	52
Gambar 4.2 <i>Confusion Matrix</i> Kinerja YOLOv8m-seg.....	53
Gambar 4.3 Visualisasi Luaran Hasil YOLOv8m-seg pada Kasus TB-Positif.....	53
Gambar 4.4 Pemetaan Distribusi Lesi Berdasarkan Kuadran.....	54
Gambar 4. 5 Output Model Yolov8m-seg dalam Deteksi Lesi dan Segmentasi	55
Gambar 4.6 Gambaran Umum Pembagian Kuadran Paru	55
Gambar 4.7 Area Piksel yang dijadikan Acuan untuk Penentuan Tulang Rusuk.....	56
Gambar 4.8 Penentuan Garis Vertikal dan Horizontal pada Paru Menggunakan Landmark Tulang Rusuk	57
Gambar 4. 9 <i>Learning Curve</i> Model Unimodal: (a) Model A (<i>CXR-Only</i>) dan (b) Model B (<i>Audio-Only</i>)	60
Gambar 4. 10 <i>Confusion Matrix</i> Model Unimodal: (a) Model A (<i>CXR-Only</i>) dan (b) Model B (<i>Audio-Only</i>)	61
Gambar 4.11 <i>Confusion matrix</i> untuk (a) <i>Max Fusion</i> , (b) <i>Mixture of Experts</i> (ME), dan (c) <i>Weighted Average Fusion</i> pada data uji	63
Gambar 4.12 Perbandingan Kurva ROC antara Model Unimodal dan Skema <i>Fusion</i> pada Set Pengujian	64
Gambar 4.13 Prediksi Per-Sampel untuk Model CXR, Audio, dan <i>Weighted Average</i>	65
Gambar 4.14 Visualisasi <i>Grad-CAM</i> dan <i>Saliency Map</i> pada Data Kelas Normal ...	66
Gambar 4.15 Visualisasi <i>Grad-CAM</i> dan <i>Saliency Map</i> pada Data Kelas TB	67
Gambar 4.16 CXR Pasien ID 039	69

DAFTAR TABEL

Tabel 1.1 Relevansi Penelitian	5
Tabel 3.1 Alat dan Bahan Penelitian	31
Tabel 3.2 Distribusi Data Citra X-ray di Setiap Kelas	35
Tabel 3.3 Pemetaan Kuadran CXR terhadap Lokasi Auskultasi Paru	40
Tabel 4.1 Distribusi Dataset YOLOv8-Seg untuk Deteksi dan Segmentasi Lesi	49
Tabel 4.2 Analisis Parameter, Ukuran Model, dan Kinerja Deteksi YOLOv8-Seg ...	50
Tabel 4.3 Perbandingan Kinerja <i>Bounding-Box</i> dan <i>Mask</i> pada Varian YOLOv8-Seg	51
Tabel 4.4 Struktur Label dan Pairing CXR–Audio pada Dataset Multimodal.....	58
Tabel 4.5 Distribusi Dataset Multimodal Hasil Smart Data Pairing	59
Tabel 4.6 Kinerja Kuantitatif Model Unimodal (<i>CXR-Only</i> dan <i>Audio-Only</i>)	59
Tabel 4.7 Perbandingan Kinerja Model Unimodal dan Multimodal pada Set Pengujian.....	62

DAFTAR SINGKATAN

TB	: Tuberkulosis
DL	: Deep Learning
CXR	: Chest X-ray
AI	: Artificial Intelligence
CNN	: Convolutional Neural Network
CRNN	: Convolutional Recurrent Neural Network
LSTM	: Long Short Term Memory
WT	: Wavelet Transform
MFCC	: Mel-Frequency Cepstral Coefficients
AE	: Autoencoder
RAN	: Residual Attention Network
VIT	: Vision Transformer
CLAHE	: Contrast Limited Adaptive Histogram Equalization
AUC	: Area Under Curve

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Tuberkulosis (TB) menjadi salah satu permasalahan kesehatan global yang serius. Pada tahun 2024, diperkirakan terdapat 10,7 juta kasus baru TB secara global, menunjukkan penurunan kecil dibanding tahun 2023 namun masih lebih tinggi dibanding tingkat sebelum pandemi. Selain itu, 1,23 juta kematian terjadi akibat TB, menjadikannya salah satu penyakit infeksi dengan mortalitas tertinggi di dunia. Indonesia menempati posisi kedua dengan menyumbang sekitar 10% dari total kasus TB global, setelah India. Kondisi ini menegaskan pentingnya penguatan upaya pencegahan, deteksi dini, dan pengobatan yang efektif untuk menurunkan beban TB secara signifikan [1], [2].

Seiring dengan kemajuan teknologi, pendekatan berbasis *Deep Learning* telah banyak dikembangkan untuk membantu dalam deteksi TB. Penelitian awal berfokus pada penggunaan satu jenis data (*single-modal*), terutama citra X-ray. Sebagai contoh, penelitian oleh Alshmrani dkk. [3] menggunakan *Deep Learning* pada citra X-ray untuk mendiagnosis berbagai penyakit paru, sementara studi oleh A'yuni dkk. [4] berhasil mengembangkan sistem deteksi TB berbasis web dengan model ResNet-101. Namun, dalam dunia medis, diagnosis yang akurat sering kali tidak dapat dicapai hanya dengan satu jenis data saja. Sejalan dengan itu, modalitas lain seperti suara paru juga dieksplorasi. Studi oleh Alhamdi dkk. [5] dan pengembangan sistem skrining mandiri LUDESC [6] menunjukkan potensi besar suara paru dalam mendeteksi kelainan pernapasan, namun tetap terbatas sebagai pendekatan *single-modal*.

Mengembangkan eksplorasi pada modalitas audio, penelitian yang dilakukan oleh Rajasekar dkk. [7] berfokus pada analisis suara batuk sebagai pendekatan unimodal untuk deteksi TB. Dalam studi mereka, rekaman audio batuk dari 1.105 individu yang berasal dari CODA TB DREAM Challenge Dataset diubah menjadi representasi visual berupa gambar spektrogram. Dengan menggunakan model hibrida yang menggabungkan *Capsule Networks* dan *Fully Connected Neural Networks* (FCNN) penelitian ini berhasil mencapai performa yang sangat tinggi dengan *accuracy* 97%. Studi ini menegaskan bahwa meskipun masih dalam ranah unimodal,

pemilihan arsitektur *deep learning* yang tepat pada data audio dapat menghasilkan alat skrining TB yang sangat akurat dan efisien.

Menyadari keterbatasan tersebut, pendekatan multimodal yang mengintegrasikan berbagai jenis data menjadi solusi yang lebih optimal, sejalan dengan cara kerja dokter yang memerlukan informasi dari berbagai sumber. Penelitian oleh Hong-Yu Zhou dkk. [8] membuktikan hal ini dengan model IRENE, yang mengintegrasikan citra X-ray dan data medis tekstual. Hasilnya menunjukkan peningkatan AUROC yang signifikan sebesar 12% dibandingkan model berbasis citra saja (0.924 vs 0.805), menegaskan bahwa integrasi data mampu meningkatkan akurasi secara signifikan.

Selain integrasi data citra dan tekstual, efektivitas pendekatan multimodal juga terbukti pada kombinasi data audio dan klinis dalam penelitian AcousticTB oleh Kesarwani [9]. Model ini mengintegrasikan dua jenis data yang berbeda: fitur akustik yang diekstrak dari suara batuk dan data klinis-demografis pasien. AcousticTB menggunakan arsitektur bertingkat (*stacked*) yang inovatif, di mana sebuah CNN mengekstrak fitur dari audio, yang kemudian digabungkan dengan data klinis yang diproses oleh *classifier* XGBoost serta *stacker Logistic Regression*. Hasilnya, model ini mencapai nilai ROC-AUC sebesar 0.850 dan terbukti lebih unggul dibandingkan pendekatan lain yang hanya menggunakan suara batuk maupun yang sudah menggabungkan suara batuk dengan metadata. Selain itu, keunggulan utama dari AcousticTB adalah ketahanannya terhadap kebisingan lingkungan, yang menunjukkan potensinya untuk aplikasi di dunia nyata.

Dalam diagnosis medis multimodal, strategi fusi data pada *Deep Learning* (DL) sangat penting untuk memodelkan hubungan nonlinier yang kompleks dan dapat dikategorikan menjadi tiga pendekatan utama. *Early fusion* menggabungkan data mentah di tingkat input, seringkali melalui konkatenasi. *Intermediate fusion* menyatukan representasi fitur dari masing-masing modalitas di lapisan tengah jaringan, yang memungkinkan interaksi kompleks melalui mekanisme seperti *cross-attention*. Sementara itu, *late fusion* bekerja di tingkat keputusan dengan mengagregasi hasil prediksi dari beberapa model *unimodal* yang dilatih secara terpisah [10], [11], [12]. Pemilihan strategi fusi data yang tepat sangat dipengaruhi oleh karakteristik dan heterogenitas sumber data yang digunakan. Ketika setiap modalitas memiliki

distribusi, skala, dan representasi fitur yang berbeda, pendekatan *late fusion* menjadi strategi yang paling sesuai. Hal ini karena *late fusion* memungkinkan setiap model unimodal untuk belajar secara mandiri sesuai karakteristik datanya masing-masing

Pendekatan ini diimplementasikan melalui teknik *weighted average ensemble* [11], di mana bobot kontribusi tiap model ditentukan secara optimum menggunakan proses *grid search*. Metode tersebut mengeksplorasi berbagai kombinasi bobot dalam ruang parameter yang telah ditetapkan untuk menemukan konfigurasi paling efektif dalam mengintegrasikan keluaran antar-model. Setiap kombinasi dievaluasi menggunakan metrik performa yang relevan untuk menilai keseimbangan kontribusi antar-model terhadap hasil akhir. Dengan cara ini, *late fusion* tidak hanya mempertahankan keunggulan representasi masing-masing modalitas, tetapi juga meningkatkan stabilitas, mengurangi bias model tunggal, dan memperkuat kemampuan generalisasi terhadap variasi data multimodal yang kompleks.

Meskipun pendekatan multimodal telah terbukti efektif, terdapat celah penelitian yang signifikan hingga saat ini, belum ada penelitian yang secara khusus mengintegrasikan dua modalitas paling objektif dari pemeriksaan langsung pasien, yaitu citra X-ray dan suara paru, untuk diagnosis Tuberkulosis. Sebagian besar penelitian multimodal yang ada masih terbatas pada kombinasi citra X-ray dengan data tekstual dari rekam medis [8]. Walaupun data tekstual memberikan konteks, ia memiliki kelemahan seperti subjektivitas interpretasi dokter, tantangan privasi data, dan keterbatasan anotasi [13]. Sebaliknya, citra X-ray dan suara paru bersifat lebih objektif, menjadikannya data yang ideal untuk pengembangan model deteksi penyakit paru.

Namun, terdapat tantangan praktis yang signifikan, yaitu belum tersedianya dataset terpadu yang berisi data citra X-ray (CXR) dan rekaman suara paru dari pasien yang sama secara bersamaan. Akibatnya, penelitian ini harus memanfaatkan dataset yang terpisah, yang menimbulkan kompleksitas lebih lanjut karena perbedaan skema pelabelan. Sebagai contoh, dataset suara paru seperti ICBHI [14], [15] umumnya diklasifikasikan berdasarkan kelas auskultasi seperti crackles, sementara dataset citra X-ray dikategorikan berdasarkan diagnosis penyakit (Normal dan Tuberkulosis). Meskipun demikian, kedua modalitas ini dapat disinkronkan secara konseptual berdasarkan fakta klinis bahwa lesi akibat Tuberkulosis, seperti infiltrat dan proses

peradangan, merupakan penyebab patofisiologis dari munculnya suara *crackles* [16]. Hubungan kausal ini memberikan landasan yang valid untuk mengintegrasikan kedua jenis data tersebut dalam sebuah model deteksi.

Pada penelitian ini, akan difokuskan pada penggunaan dan integrasi dua modalitas dalam deteksi Tuberkulosis citra X-ray dan suara paru. Tahap awal melibatkan deteksi lesi pada citra X-ray menggunakan model YOLOv8-seg [17]. Mengingat tidak tersedianya dataset yang sinkron, output dari model YOLOv8-seg ini digunakan untuk menerapkan strategi *smart data pairing* konseptual, di mana citra X-ray kategori Tuberkulosis (TB) dipasangkan dengan data suara paru berlabel *crackles* (ronki), berdasarkan fakta klinis yang menghubungkan keduanya. Selanjutnya, untuk mengintegrasikan data yang telah dipadankan ini, akan diimplementasikan dan dievaluasi secara mendalam strategi *late fusion*. Pendekatan ini dipilih karena kemampuannya untuk memungkinkan setiap cabang *encoder* mempelajari representasi fitur yang kaya dari modalitasnya masing-masing sebelum digabungkan. Diharapkan, kombinasi dari deteksi lesi yang akurat oleh YOLOv8, data pairing yang relevan, dan arsitektur *late fusion* yang dioptimalkan, dapat meningkatkan akurasi deteksi Tuberkulosis secara signifikan.

1.2 Rumusan Masalah

Berdasarkan latar belakang, penelitian ini berfokus pada sejumlah tantangan utama dalam diagnosis Tuberkulosis (TB) berbasis multimodal. Tantangan pertama adalah merancang dan mengimplementasikan sebuah arsitektur *deep learning* multimodal yang efektif dengan strategi *late fusion*, yang mampu mengintegrasikan fitur-fitur kompleks dari *encoder* citra dan *encoder* audio. Selanjutnya, penelitian ini mendapati tantangan implementasi dan validasi metode *Smart Data Pairing* berbasis output deteksi lesi (YOLOv8) sebagai solusi untuk menciptakan dataset gabungan yang relevan secara klinis dari sumber data yang tidak sinkron. Puncak dari penelitian ini adalah pembuktian dan pengukuran peningkatan performa yang dapat dicapai oleh model fusi multimodal. Peningkatan ini akan dievaluasi secara kuantitatif dengan membandingkannya terhadap model *baseline single-modal*.

1.3 Tujuan Penelitian

1. Mengimplementasikan metode *Smart Data Pairing* yang dipandu oleh model deteksi lesi (YOLOv8) untuk menghasilkan dataset gabungan (*fused dataset*) yang relevan secara klinis dari sumber data citra X-ray dan audio paru yang tidak sinkron.
2. Merancang dan membangun sebuah model klasifikasi Tuberkulosis multimodal dengan arsitektur *late fusion*, yang secara efektif mengintegrasikan fitur dari *encoder* citra dan *encoder* audio.
3. Mengevaluasi dan membandingkan performa model fusi multimodal yang diusulkan terhadap model baseline *single-modal*.

1.4 Relevansi Penelitian

Tabel 1.1 Relevansi Penelitian

No	Referensi	Dataset	Metode	Hasil
1	Impact Of Using Various X-Ray Dataset in Detecting Tuberculosis Based on Deep Learning, 2025 [4]	<i>Montgomery, Belarus</i> , dan <i>RSNA CXR</i> Data Sekunder 11 TB dan 12 Normal	ResNet-101 Continuous Learning +	<i>Accuracy</i> 0.992
2	Improved Lung Sound Classification Model Using Combined Residual Attention Network and Vision Transformer for Limited Dataset, 2024 [5]	ICBHI 2017 dataset	Residual Attention Network (RAN) + Vision Transformer (ViT)	<i>Specificity</i> 0.0728 <i>Sensitivity</i> 0.9283 <i>Average Score</i> of 0.9505
3	Detection of Tuberculosis using Cough Audio Analysis: a Deep Learning Approach with Capsule Networks, 2024 [7]	CODA TB DREAM Challenge Dataset	Capsule Networks + FCNN	<i>Accuracy</i> 0.97 <i>Sensitivity</i> 0.98 <i>Specificity</i> 0.96 <i>F1-Score</i> 0.97 <i>Precision</i> 0.97
4	A Transformer-based Representation-learning Model with Unified Processing of Multimodal Input for	Pulmonary Disease Dataset & Multimodal COVID-19	IRENE: <i>Unified Multimodal Transformer (MDT)</i> +	AUROC IRENE: 0.924 Image-only: 0.805 Early Fusion: 0.835 Late Fusion: 0.826

	Clinical Diagnostics, 2023 [8]	Dataset (MMC)	<i>Bidirectional Multimodal Attention.</i>	Perceiver: 0.858 GIT: 0.848
5	AcousticTB: A Hybrid Deep Learning and Gradient Boosting Framework for Noise-Robust Tuberculosis Screening from Cough Audio [9]	CODA DREAM TB Dataset	CNN (Spectrogram) + XGBOOST Classifier Logistic Regression stacker	Accuracy 0.781 AUROC 0.85 AUPRC 0.748 Sensitivity 0.729 Specificity 0.804
6	<i>AVaTER</i> : Fusing Audio, Visual, and Textual Modalities Using Cross-Modal Attention for Emotion Recognition, 2024 [18]	MAViTE-Bangla Dataset	<i>Cross Attention mechanisms</i>	<i>Weighted F1-Score: 0.64</i>
7	Weighted Average Ensemble Deep Learning Model for Stratification of Brain Tumor in MRI Images, 2023 [11]	The Cancer Genome Atlas (TCGA) 3929 MRI Brain Images	<i>Weighted Average Ensemble</i>	Accuracy: 0.98 F1-Score: 0.985 Sensitivity: 0.987 Precision: 0.9825
8	Deep Learning Enabled Multimodal Data Fusion for Lung Disease Classification, 2023 [19]	Dataset 65.000 rekaman X-ray dan data rekam medis pasien	<i>Late Fusion dan Intermediate Fusion</i>	<i>Accuracy</i> Late Fusion: 0.8974 Intermediate Fusion: 0.913
9	An Improved Deep Learning Framework for Multimodal Medical Data Analysis, 2024 [20]	Data Rekam Medis <i>Government Medical College</i> Uttarakhand, India	<i>Self Attention</i>	<i>Accuracy 0.9559</i>
10	Multimodal Cross-And Self-Attention Network for Speech Emotion Recognition, 2021 [12]	Dataset IEMOCAP & MELD	<i>Multimodal Cross Attention and Self Attention Network (MCSAN)</i>	IEMOCAP <i>Weighted Accuracy (WA):</i> 0.612 ± 0.012 <i>Unweighted Accuracy (UA):</i> 0.560 ± 0.019 MELD Weighted Average F1 Score: 0.592
11	Predicting Tuberculosis from	CODA TB DREAM	<i>Logistic Regression (LR),</i>	Audio: AUC 0.70 ± 0.05

	Real-World Cough Audio Recordings and Metadata, 2023 [21]	Challenge Dataset	<i>Support Vector Machine</i> (SVM), <i>Multi-Layer Perceptron</i> (MLP), <i>Random Forest</i> (RF), <i>AdaBoost</i> (AB), and <i>CNN</i>	Audio + Metadata: AUC 0.81±0.05
12	End-to-End Detection of a Landing Platform for Offshore UAVs Based on a Multimodal Early Fusion Approach, 2023 [22]	UAV landing operations (offshore & onshore) using ArTuga multimodal fiducial marker	<i>Early Fusion</i>	Detection Recalls 99%
13	Usulan Penelitian Deteksi Penyakit Paru Menggunakan Metode <i>Smart Data Pairing</i> dan <i>Decision Fusion</i> untuk Integrasi Citra X-Ray dan Suara Paru	CXR Shenzen Dataset, Montgomery Dataset Audio ICBHI 2017 Dataset	Smart Data Pairing (Yolov8) Late Fusion (CNN+CRNN)	

BAB 5

PENUTUP

5.1 Kesimpulan

1. Penelitian ini telah berhasil membangun dan mengimplementasikan sistem deteksi tuberkulosis berbasis multimodal yang memanfaatkan dua modalitas objektif, yaitu citra X-ray dan suara paru, dengan pendekatan *Smart Data Pairing* dan *late fusion*. Meskipun penelitian ini menggunakan data sekunder dan belum mencapai tahap pengembangan sistem aplikasi klinis, rancangan arsitektur dan pipeline pemrosesan telah tervalidasi secara komputasional dan klinis.
2. Penelitian ini berhasil mengintegrasikan model ResNet-50 sebagai encoder citra dan CRNN sebagai encoder audio ke dalam kerangka multimodal. Proses pairing yang dipandu lokasi lesi dari YOLOv8 memungkinkan sinkronisasi dua modalitas yang berasal dari dataset berbeda, sehingga membentuk dataset terintegrasi yang relevan secara klinis tanpa memerlukan data primer. Arsitektur fusion berbasis *weighted average* menghasilkan peningkatan performa yang signifikan dibandingkan model unimodal.
3. Hasil eksperimen menunjukkan bahwa model unimodal CXR dan audio memiliki keterbatasan masing-masing, terutama dalam mendeteksi kasus TB dengan lesi samar atau rekaman audio yang terpapar *noise*. Namun, setelah integrasi multimodal dilakukan, performa model meningkat drastis dengan *recall* yang sangat tinggi sebesar 0.92, menjadikan model lebih aman digunakan untuk tujuan skrining medis karena mampu meminimalkan risiko kasus TB terlewat. Visualisasi *Grad-CAM* dan *Saliency Map* juga membuktikan bahwa model fokus pada area anatomis dan pola akustik yang relevan secara klinis.

5.2 Saran

Penelitian selanjutnya disarankan untuk menggunakan data primer dari pasien agar model dapat dievaluasi secara langsung berdasarkan kondisi klinis nyata, bukan hanya melalui pairing konseptual, sehingga integrasi multimodal menjadi lebih valid dan robust. Selain itu, peningkatan kualitas serta kuantitas dataset audio perlu menjadi prioritas mengingat performa encoder audio sangat dipengaruhi oleh *noise*, variasi

teknik perekaman, dan inkonsistensi pola napas. Penggunaan mikrofon medis berkualitas tinggi serta lingkungan perekaman yang terkontrol berpotensi meningkatkan akurasi model secara signifikan. Strategi *late fusion* juga dapat dikembangkan lebih lanjut menggunakan pendekatan yang lebih adaptif seperti *gated fusion*, *attention-based fusion*, atau *mixture of experts*, sehingga kontribusi setiap modalitas dapat dipelajari secara dinamis dan tidak terbatas pada bobot statis seperti pada penelitian ini. Untuk aplikasi klinis, model multimodal dapat dikembangkan menjadi sistem yang mampu menerima input CXR dan audio secara langsung melalui backend yang mendukung continuous learning, serta memanfaatkan platform cloud computing seperti *DigitalOcean* atau AWS untuk mendukung pembaruan model secara otomatis dan berkala.

DAFTAR PUSTAKA

- [1] World Health Organization, “Global Tuberculosis Report 2025,” Oct. 2025.
- [2] G. B. Migliori *et al.*, “Clinical Standards for the Diagnosis, Treatment and Prevention of TB Infection,” *International Journal of Tuberculosis and Lung Disease*, vol. 26, no. 3, pp. 190–205, Mar. 2022, doi: 10.5588/ijtld.21.0753.
- [3] G. M. M. Alshmrani, Q. Ni, R. Jiang, H. Pervaiz, and N. M. Elshennawy, “A Deep Learning Srchitecture for Multi-class Lung Diseases Classification Using Chest X-ray (CXR) Images,” *Alexandria Engineering Journal*, vol. 64, pp. 923–935, Feb. 2023, doi: 10.1016/j.aej.2022.10.053.
- [4] Q. A’yuni, N. Nasaruddin, M. Irhamsyah, M. Azhary, and R. Roslidar, “Intelligent Tuberculosis Detection System with Continuous Learning on X-ray Images,” *Journal of Electronics, Electromedical Engineering, and Medical Informatics*, vol. 7, no. 1, pp. 130–141, Jan. 2025, doi: 10.35882/jeeemi.v7i1.572.
- [5] M. Jurej, R. Roslidar, and Y. Yunida, “Improved Lung Sound Classification Model Using Combined Residual Attention Network and Vision Transformer for Limited Dataset,” *Indonesian Journal of Electrical Engineering and Informatics*, vol. 12, no. 4, pp. 1085–1097, Dec. 2024, doi: 10.52549/ijeei.v12i4.5530.
- [6] “Ludesc.” Accessed: Mar. 19, 2025. [Online]. Available: <https://www.ludesc.com/>
- [7] S. J. S. Rajasekar *et al.*, “Detection of tuberculosis using cough audio analysis: a deep learning approach with capsule networks,” *Discover Artificial Intelligence*, vol. 4, no. 1, Dec. 2024, doi: 10.1007/s44163-024-00179-4.
- [8] H. Y. Zhou *et al.*, “A Transformer-based Representation-learning Model with Unified Processing of Multimodal Input for Clinical Diagnostics,” *Nat Biomed Eng*, vol. 7, no. 6, pp. 743–755, Jun. 2023, doi: 10.1038/s41551-023-01045-x.
- [9] S. Kesarwani, “AcousticTB: A Hybrid Deep Learning and Gradient Boosting Framework for Noise-Robust Tuberculosis Screening from Cough Audio,” Sep. 09, 2025. doi: 10.36227/techrxiv.175742700.07240558/v1.
- [10] S. R. Stahlschmidt, B. Ulfenborg, and J. Synnergren, “Multimodal deep learning for biomedical data fusion: A review,” Mar. 01, 2022, *Oxford University Press*. doi: 10.1093/bib/bbab569.

- [11] V. Anand *et al.*, “Weighted Average Ensemble Deep Learning Model for Stratification of Brain Tumor in MRI Images,” *Diagnostics*, vol. 13, no. 7, Apr. 2023, doi: 10.3390/diagnostics13071320.
- [12] L. Sun, B. Liu, J. Tao, and Z. Lian, “Multimodal Cross- And Self-Attention Network for Speech Emotion Recognition,” in *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings*, Institute of Electrical and Electronics Engineers Inc., 2021, pp. 4275–4279. doi: 10.1109/ICASSP39728.2021.9414654.
- [13] I. Li *et al.*, “Neural Natural Language Processing for Unstructured Data in Electronic Health Records: a Review,” Jul. 2021, [Online]. Available: <http://arxiv.org/abs/2107.02975>
- [14] B. M. Rocha *et al.*, “A Respiratory Sound Database for the Development of Automated Classification,” 2018, pp. 33–37. doi: 10.1007/978-981-10-7419-6_6.
- [15] B. M. Rocha *et al.*, “An open access database for the evaluation of respiratory sound classification algorithms,” *Physiol Meas*, vol. 40, no. 3, p. 035001, Mar. 2019, doi: 10.1088/1361-6579/ab03ea.
- [16] M. Sarkar, I. Madabhavi, N. Niranjana, and M. Dogra, “Auscultation of the respiratory system,” *Ann Thorac Med*, vol. 10, no. 3, pp. 158–168, Jul. 2015, doi: 10.4103/1817-1737.160831.
- [17] “YOLOv8 Segmentation in Python - Ultralytics.” Accessed: Nov. 16, 2025. [Online]. Available: <https://www.ultralytics.com/blog/segmentation-with-pre-trained-ultralytics-yolov8-models-in-python>
- [18] A. Das, M. Sen Sarma, M. M. Hoque, N. Siddique, and M. A. A. Dewan, “AVaTER: Fusing Audio, Visual, and Textual Modalities Using Cross-Modal Attention for Emotion Recognition,” *Sensors*, vol. 24, no. 18, p. 5862, Sep. 2024, doi: 10.3390/s24185862.
- [19] S. Kumar, O. Ivanova, A. Melyokhin, and P. Tiwari, “Deep Learning Enabled Multimodal Data Fusion for Lung Disease Classification,” *Inform Med Unlocked*, vol. 42, Jan. 2023, doi: 10.1016/j.imu.2023.101367.
- [20] S. Kumar and S. Sharma, “An Improved Deep Learning Framework for Multimodal Medical Data Analysis,” *Big Data and Cognitive Computing*, vol. 8, no. 10, Oct. 2024, doi: 10.3390/bdcc8100125.
- [21] G. P. Kafentzis *et al.*, “Predicting Tuberculosis from Real-World Cough Audio Recordings and Metadata,” Jul. 2023, [Online]. Available: <http://arxiv.org/abs/2307.04842>
- [22] F. S. Neves, R. M. Claro, and A. M. Pinto, “End-to-End Detection of a Landing Platform for Offshore UAVs Based on a Multimodal Early

- Fusion Approach,” *Sensors*, vol. 23, no. 5, p. 2434, Feb. 2023, doi: 10.3390/s23052434.
- [23] “The Radiology Assistant : Lung Segments and Bronchi.” Accessed: Jul. 10, 2025. [Online]. Available: <https://radiologyassistant.nl/chest/lung-anatomy/lung-segments>
- [24] “The-bronchopulmonary-segments-of-the-lungs-1.png (1800×950).” Accessed: Jul. 10, 2025. [Online]. Available: <https://cdn.lecturio.com/assets/The-bronchopulmonary-segments-of-the-lungs-1.png>
- [25] A. S. Whitley, C. Sloane, G. Hoadley, A. D. Moore, and C. W. Alsop, *CLARK’S POSITIONING IN RADIOGRAPHY*, vol. 14th Edition. 2006.
- [26] F. Gaillard, L. Silverstone, and T. Walizai, “Tuberculosis (pulmonary manifestations),” *Radiopaedia.org*, Feb. 2010, doi: 10.53347/RID-8631.
- [27] O. Bashir, M. Wilczek, and A. Campos, “Post-primary pulmonary tuberculosis,” in *Radiopaedia.org*, Radiopaedia.org, 2012. doi: 10.53347/rID-17867.
- [28] M. Yonso, “Active Pulmonary Tuberculosis,” *Radiopaedia.org*, Dec. 2023, doi: 10.53347/RID-98551.
- [29] C. A. Peloquin and G. R. Davies, “The Treatment of Tuberculosis,” *Clin Pharmacol Ther*, vol. 110, no. 6, pp. 1455–1466, Dec. 2021, doi: 10.1002/cpt.2261.
- [30] K. Santosh, S. Allu, S. Rajaraman, and S. Antani, “Advances in Deep Learning for Tuberculosis Screening using Chest X-rays: The Last 5 Years Review,” *J Med Syst*, vol. 46, no. 11, Nov. 2022, doi: 10.1007/s10916-022-01870-8.
- [31] M. Irhamsyah, Q. A’yuni, K. Saddami, N. Nasaruddin, K. Munadi, and F. Arnia, “Impact of Using Various X-Ray Dataset in Detecting Tuberculosis Based on Deep Learning,” *Radioelectronic and Computer Systems*, vol. 2025, no. 1, pp. 165–186, Feb. 2025, doi: 10.32620/reks.2025.1.12.
- [32] R. Roslidar *et al.*, “Stetoskop Digital Pintar untuk Merekam Suara Auskultasi Paru dan Jantung,” IDS000009552, 2023
- [33] “Tuberculosis Chest X-rays (Montgomery).” Accessed: May 12, 2025. [Online]. Available: <https://www.kaggle.com/datasets/raddar/tuberculosis-chest-xrays-montgomery>
- [34] “Tuberculosis Chest X-rays (Shenzhen).” Accessed: May 12, 2025. [Online]. Available: <https://www.kaggle.com/datasets/raddar/tuberculosis-chest-xrays-shenzhen>

- [35] S. M. Pizer *et al.*, “Adaptive histogram equalization and its variations,” *Comput Vis Graph Image Process*, vol. 39, no. 3, pp. 355–368, Sep. 1987, doi: 10.1016/S0734-189X(87)80186-X.
- [36] K. Zuiderveld, “Contrast Limited Adaptive Histogram Equalization,” *Graphics gems IV*, pp. 474–485, 1994.
- [37] M. Rosenblatt, “Cumulants and cumulant spectra,” 1983, pp. 369–382. doi: 10.1016/S0169-7161(83)03019-9.
- [38] V. K. Iyer, P. A. Ramamoorthy, H. Fan, and Y. Ploysongsang, “Reduction of Heart Sounds from Lung Sounds by Adaptive Filtering,” *IEEE Trans Biomed Eng*, vol. BME-33, no. 12, pp. 1141–1148, Dec. 1986, doi: 10.1109/TBME.1986.325693.
- [39] M. Fei, W. Yixuan, S. Yan, C. Maolin, Y. Liman, and S. Dongkai, “A new type of wavelet de-noising algorithm for lung sound signals,” in *2018 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, IEEE, Dec. 2018, pp. 2544–2548. doi: 10.1109/BIBM.2018.8621442.
- [40] A. Srivastava, S. Jain, R. Miranda, S. Patil, S. Pandya, and K. Kotecha, “Deep learning based respiratory sound analysis for detection of chronic obstructive pulmonary disease,” *PeerJ Comput Sci*, vol. 7, pp. 1–22, 2021, doi: 10.7717/PEERJ-CS.369.
- [41] X. Xu and R. Sankar, “Classification and Recognition of Lung Sounds Using Artificial Intelligence and Machine Learning: A Literature Review,” Oct. 01, 2024, *Multidisciplinary Digital Publishing Institute (MDPI)*. doi: 10.3390/bdcc8100127.
- [42] R. Qureshi *et al.*, “A Comprehensive Systematic Review of YOLO for Medical Object Detection (2018 to 2023),” Jul. 17, 2023. doi: 10.36227/techrxiv.23681679.v1.
- [43] J. Terven and D. Cordova-Esparza, “A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS,” Feb. 2024, doi: 10.3390/make5040083.
- [44] D. Chenna, “Evolution of Convolutional Neural Network (CNN): Compute vs Memory bandwidth for Edge AI,” *FEEDFORWARD*, vol. 2, no. 3, Sep. 2023.
- [45] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” Dec. 2015, [Online]. Available: <http://arxiv.org/abs/1512.03385>
- [46] P.-A. Grumiaux, S. Kitic, L. Girin, and A. Guérin, “Improved feature extraction for CRNN-based multiple sound source localization,” May 2021, [Online]. Available: <http://arxiv.org/abs/2105.01897>

- [47] C. M. Bishop, “Pattern Recognition and Machine Learning,” Cambridge, Feb. 2006.
- [48] K. J. van Stralen, V. S. Stel, J. B. Reitsma, F. W. Dekker, C. Zoccali, and K. J. Jager, “Diagnostic methods I: sensitivity, specificity, and other measures of accuracy,” *Kidney Int*, vol. 75, no. 12, pp. 1257–1263, Jun. 2009, doi: 10.1038/ki.2009.92.
- [49] “Roboflow: Computer vision tools for developers and enterprises.” Accessed: Aug. 17, 2025. [Online]. Available: <https://roboflow.com/>